コア構成とヒュージページ 実験結果

- 実験日: 2026 年 10 月 19 日（1 回目 14:17、P コアの測り直し 14:47・14:58）
- 担当: 櫻田
- 機材: 学科 PC EE00025（Intel Core Ultra 5 225U）、ネイティブ Linux（Ubuntu 24.04.3）
- 条件: AC 電源、電源プロファイル「パフォーマンス」に固定、モデル `stories15M.bin`、`-n 256 -t 0 -s 42`
- スクリプト: `core_thread_check.sh`（ブランチ `dev/sakurada`）
- 生データ: `memlab/native_core_EE00025_20261019/`（1 回目）、`memlab/native_pcore_EE00025_20261019/`（測り直し 2 回分）

ひとことで言うと（測り直し後の結論）

1. **ヒュージページの効果は、どのコア構成でも約 3〜6%。** 小さいが、測り直しでは 10 回中ほぼ 10 回で速く、確かな効果。
2. **一番速い構成は P4_HT（P コア 2 つ × 2 本、約 645 tok/s）。** ヒュージページを使うと約 670 tok/s。
3. **ヒュージページは、出力層より層の方に効く**（層 4〜8%、出力層 0〜4%）。
4. **CPU 0 を使うかどうかで、速さはほとんど変わらない**（1 スレッドで 442 tok/s と 445 tok/s）。
5. 1 回目の測定では P コアの結果が大きくぶれたが、**測り直し（2 回）ではどの構成も安定していた**（ぶれ 1〜3%）。1 回目のぶれは、その時だけの一時的な原因によるものと考えられる。
6. そのため、1 回目で出した **「層は E コア、出力層は P コアにすると約 7% 速くなる」という見積もりは取り消す。** 測り直しでは、層も出力層も P4_HT が一番速く、構成を切り替える利点はなかった。

> 1〜5 章は 1 回目（14:17）の測定結果で、P コアの値にはぶれの影響がある。訂正と最新の結果は 8 章。

---

1. 何を測ったか

目的

ヒュージページ（`-w 3`）の効果が、

- **コアの種類**（P コアか E コアか）
- **スレッド数**（1・2・4）
- **計算の部分**（層か、出力層か）

によってどう変わるかを、班の Day4 案 2 の表と同じコア構成で調べた。

コア構成（7 通り）

名前	使う CPU	中身	由来
P1	0	P コア 1 つ	班の表と同じ
P2	0, 2	P コア 2 つ（1 本ずつ）	班の表と同じ
P4_HT	0〜3	P コア 2 つ × 2 本（ハイパースレッディング）	班の表と同じ
E4	4〜7	E コア 4 つ（同じまとまり）	班の表と同じ
X4_2_2	4, 5, 8, 9	E コア 4 つ（2 つのまとまりに 2+2）	班の表と同じ
E1	4	E コア 1 つ	追加
E2	4, 5	E コア 2 つ	追加

それぞれを `-w 0`（元のまま、4KB ページ）と `-w 3`（位置揃え＋ヒュージページ）で、毎周ランダムな順番で 10 周測った（合計 140 回）。**140 回すべてで、生成された文章は一致した。**

測った時間

項目	中身
層の合計	6 層分の計算時間（重み 24MB）
出力層	最後の rmsnorm ＋ 分類器（重み 37MB）
forward	1 トークンあたりの合計（層の合計 ＋ 出力層）

---

2. TLB の範囲：ヒュージページは P コアでも E コアでも効いている

ページ 1 枚につき 1 回だけ読む測定で、「住所を調べる手間」だけを測った（`tlbreach`）。

読む範囲	P コア 4KB	P コア ヒュージページ	E コア 4KB	E コア ヒュージページ
4MB まで	約 0.7 ns	約 0.66 ns	約 1.4 ns	約 1.27 ns
16MB	1.72 ns	**0.65 ns**	8.83 ns	**1.23 ns**
58MB	2.07 ns	**0.68 ns**	10.1 ns	**1.25 ns**

- 4KB ページは、TLB（住所を覚えるメモ帳）に入りきらなくなる 8〜16MB を超えると遅くなる。ヒュージページは最後まで速いまま。
- **E コアは、4KB ページで住所を調べる手間がとても大きい**（P コアの約 5 倍）。

---

3. 構成ごとの速さとヒュージページの効果

構成	速さ（`-w 0` → `-w 3`）	ヒュージページの効果（forward）	結果の安定性
P1	383 → 411 tok/s	1.047 倍（10 回中 7 回で速い）	ぶれ大
P2	480 → 499	1.063 倍（8/10）	ややぶれ
P4_HT	400 → 444	（1.114 倍）※	**層がぶれ大**
E4	477 → 487	1.017 倍（8/10）	安定
X4_2_2	**540 → 544**	1.017 倍（7/10）	安定
E1	205 → 209	1.034 倍（7/10）	安定
E2	363 → 381	1.033 倍（9/10）	安定

※ P4_HT は層の時間が大きくぶれているので、この倍率は信用できない（4 章）。測り直しの値は 8 章。

層と出力層に分けた時間（ms/トークン、中央値）

構成	層 `-w 0`	層 `-w 3`	出力層 `-w 0`	出力層 `-w 3`	forward `-w 0`	forward `-w 3`
P1	1.177	1.085	1.396	1.319	2.584	2.404
P2	1.010	0.986	1.041	0.988	2.051	1.974
P4_HT	1.604	1.431	**0.840**	**0.784**	2.467	2.223
E4	1.023	0.992	1.040	1.030	2.063	2.020
X4_2_2	**0.929**	**0.916**	0.891	0.894	**1.821**	**1.805**
E1	2.042	1.998	2.794	2.749	4.836	4.746
E2	1.276	1.212	1.449	1.380	2.725	2.591

予想と違ったこと

(1) E コアでも、ヒュージページはあまり効かなかった

TLB の測定では E コアの方が住所を調べる手間がずっと大きかったので、「E コアの方がよく効く」と予想していた。実際は E1 で 3.4% だけだった。

考えられる理由（推測）: **E コアはそもそも計算が遅いので、住所を調べる待ち時間が計算の時間に隠れてしまう。** E1 は 1 トークン 4.8ms かかっており、メモリから読む速さに直すと約 12.6 GB/s。P コア 1 スレッドで測ったときの 26.5 GB/s の半分以下なので、E コアではメモリより計算の方が詰まっていると考えられる。

(2) 層と出力層で、効き方にはっきりした差はなかった

重みが大きい出力層の方がよく効くと予想していたが、安定している E コアの構成では、どちらも 0.5〜4% 程度だった。

---

4. P コアの結果のぶれ

10 周の最小〜最大（`-w 0`）:

構成	層の合計	出力層
P4_HT	**0.84〜2.69 ms（3 倍以上の幅）**	0.78〜0.88 ms（安定）
P1	1.05〜1.44 ms	1.19〜1.84 ms
X4_2_2（比較用）	0.90〜1.09 ms	0.87〜1.04 ms

- **P4_HT の層だけが極端にぶれている。** 層の計算は小さな行列の掛け算と、スレッド同士の待ち合わせが多い。1 つの P コアで 2 本のスレッドを動かすと、何かに邪魔されたときの影響を受けやすいのかもしれない（推測）。
- **P1（CPU 0）もぶれており、以前 CPU 2 で測ったとき（447 tok/s、ぶれ約 1%）より遅い**（383 tok/s）。CPU 0 は OS の割り込み処理などを多く受け持つことがあり、その影響の可能性がある（推測）。

班の Day4 案 2 の表との比較（forward、`-w 0`）

構成	班の表	今回
P1	2.292 ms	2.584 ms
P2	1.780 ms	2.051 ms
P4_HT	1.665 ms	2.467 ms
E4	2.124 ms	2.063 ms
X4_2_2	1.876 ms	1.821 ms

- **E コアの構成はほぼ同じ値**なので、測定条件はおおむねそろっていたと考えられる。
- **P コアの構成は、今回の方が 1〜5 割遅い。** 上のぶれが原因の可能性がある。
- **【訂正】測り直し（8 章）では、P コアの構成も班の表とほぼ同じか、やや速い値になった。CPU 0 は原因ではなかった。**

---

5. 組み合わせの見積もり（班の案 2 の A ＋ ヒュージページ）

> **【訂正】この章の見積もりは、P コアの結果がぶれていた 1 回目の測定によるもの。測り直し（8 章）では層も出力層も P4_HT が一番速く、構成を切り替える利点はなかったので、この見積もりは取り消す。**

班の案 2 の A（出力層だけコアの配分を変える）を想定し、**層と出力層それぞれで一番速い構成を使った場合**の時間を、別々に測った中央値の足し算で見積もった。

	層	出力層	合計	一番速い単独の構成（X4_2_2、ヒュージページなし）に対して
ヒュージページだけ	X4_2_2	X4_2_2	1.805 ms	1.009 倍
構成を切り替えるだけ	X4_2_2（0.929）	P4_HT（0.840）	1.769 ms（565 tok/s）	1.029 倍
両方	X4_2_2（0.916）	P4_HT（0.784）	**1.701 ms（588 tok/s）**	**1.071 倍**

- 出力層の P4_HT は安定していた（0.78〜0.88 ms）ので、この見積もりは比較的信頼できる。
- **層は E コア、出力層は P コア** という分け方になる。それぞれのコアが自分の担当の重みだけを読むことになるので、キャッシュの取り合いも起きにくい可能性がある（推測）。
- **注意**: 層と出力層の間でコアを切り替える手間は含まれていない。実装すると、この差の一部は消える可能性がある。

---

6. 班への示唆（測り直し後）

1. **一番速いのは P4_HT（P コア 2 つ × 2 本）。** E コアの X4_2_2 も速くて安定しているが、P4_HT より約 14% 遅い。
2. **案 2 の A（層と出力層でコアの配分を変える）は、このモデル・この PC では効果が見込めない。** 層・出力層とも P4_HT が一番速かった。
3. **CPU 0 を避ける必要はない。**
4. **測定は、日を変えて（または同じ日に）2 回以上行い、再現するかを確かめる。** 1 回目のように、一時的な原因で結果が大きくぶれることがある。
5. **ヒュージページは、結果を変えずに約 3〜6% 速くできる手軽な改善。** ほかの方法と組み合わせて使うのがよい。

---

7. 次の実験

- 1 回目にだけ P コアがぶれた原因を調べる（起動直後の常駐処理などの可能性。同じ条件で再現するか）。
- E コアの構成（E4、E1、E2）も、2 回目以降の安定した状態で測り直し、1 回目の値と比べる。
- ヒュージページが「出力層より層に効く」理由を調べる（層は 6 層 × 7 つの行列に加えて KV キャッシュも読むので、TLB の負担が大きい可能性がある）。

---

8. P コアの測り直し（14:47・14:58 の 2 回）

目的

1 回目の測定で P コアの結果が大きくぶれた原因が CPU 0 かどうかを確かめるため、**CPU 0 を使う構成と使わない構成** を並べて測った（`CASESET=pcore`）。条件は 1 回目と同じ（パフォーマンス、10 周、`-w 0` と `-w 3`）。2 回とも、生成された文章はすべて一致した。

名前	使う CPU	ねらい
P1_c0	0	1 回目の P1 と同じ（CPU 0 を使う）
P1_c2	2	CPU 0 を避けた P コア 1 つ
P1_c1	1	CPU 0 と同じ P コアのもう 1 本のスレッド
P2_c02	0, 2	1 回目の P2 と同じ
P2_c13	1, 3	CPU 0 を避けた P コア 2 つ
P3_HT	1〜3	CPU 0 を避けたハイパースレッディング（3 本）
P4_HT	0〜3	1 回目と同じ
X4_2_2	4, 5, 8, 9	比較用

結果（2 回の値。左が 14:47、右が 14:58）

構成	forward `-w 0`（ms）	tok/s `-w 0`	tok/s `-w 3`	10 周のぶれ（forward `-w 0`）
P1_c0	2.237 / 2.235	442 / 442	456 / 455	2.22〜2.28 / 2.22〜2.32
P1_c2	2.218 / 2.216	445 / 446	467 / 466	2.21〜2.25 / 2.20〜2.22
P1_c1	2.237 / 2.250	441 / 438	455 / 456	2.23〜2.25 / 2.23〜2.30
P2_c02	1.710 / 1.716	575 / 573	593 / 591	1.71〜1.72 / 1.71〜1.74
P2_c13	1.709 / 1.716	576 / 573	593 / 590	1.70〜1.72 / 1.71〜1.76
P3_HT	1.728 / 1.740	568 / 565	602 / 597	1.72〜1.76 / 1.73〜1.77
P4_HT	**1.543 / 1.554**	**636 / 632**	**667 / 663**	1.54〜1.56 / 1.55〜1.60
X4_2_2	1.764 / 1.768	557 / 555	573 / 573	1.75〜1.78 / 1.75〜1.79

分かったこと

- **2 回の値は 1% 以内で一致し、10 周のぶれも 1〜3% と小さい。** 1 回目の大きなぶれ（P4_HT の層で 3 倍以上）は再現しなかった。
- **CPU 0 を使っても使わなくても、ほぼ同じ。** P1_c0 と P1_c2 の差は約 1%、P2_c02 と P2_c13 は同じ値。1 回目のぶれの原因は CPU 0 ではなかった。
- **P4_HT が一番速い**（約 635 tok/s、ヒュージページで約 665 tok/s）。班の表（P4_HT 1.665 ms）より少し速い。
- 1 回目は X4_2_2 も今回より約 3% 遅かった（1.821 ms → 1.764 ms）。**1 回目は、パソコン全体が何かの処理で少し重かった**可能性がある（推測。起動直後の常駐処理など）。

ヒュージページの効果（2 回の値、同じ周どうしの比較）

構成	層	出力層	forward
P1_c0	1.067 / 1.075 倍	1.006 / 0.998 倍	1.034 / 1.030 倍
P1_c2	1.081 / 1.077 倍	1.023 / 1.016 倍	1.050 / 1.046 倍
P1_c1	1.069 / 1.074 倍	1.004 / 1.011 倍	1.033 / 1.040 倍
P2_c02	1.046 / 1.044 倍	1.019 / 1.024 倍	1.033 / 1.034 倍
P2_c13	1.041 / 1.042 倍	1.021 / 1.021 倍	1.032 / 1.031 倍
P3_HT	1.079 / 1.072 倍	1.043 / 1.043 倍	1.058 / 1.058 倍
P4_HT	1.061 / 1.066 倍	1.039 / 1.036 倍	1.050 / 1.052 倍
X4_2_2	1.029 / 1.047 倍	1.019 / 1.015 倍	1.026 / 1.031 倍

- **forward で約 3〜6% 速くなり、ほとんどの構成で 10 回中 10 回速かった。** 小さいが確かな効果。
- **層の方が出力層より効く**（層 4〜8%、出力層 0〜4%）。出力層は 1 つの大きな表を先頭から順に読むだけなのに対し、層は 6 層 × 7 つの行列を順に切り替えながら読み、さらに KV キャッシュも読む。そのため、住所を覚えるメモ帳（TLB）の負担が大きく、ヒュージページの恩恵を受けやすいのかもしれない（推測）。

組み合わせの見積もり（測り直し）

	層	出力層	合計	P4_HT（ヒュージページなし）に対して
ヒュージページだけ	P4_HT	P4_HT	1.472 ms（679 tok/s）	1.049 倍
構成を切り替えるだけ	P4_HT	P4_HT	1.543 ms	1.000 倍（切り替える利点なし）

（14:47 の値。14:58 もほぼ同じ）

TLB の範囲（測り直しでも同じ）

読む範囲	P コア 4KB	P コア ヒュージページ	E コア 4KB	E コア ヒュージページ
8MB	0.84 ns	0.65 ns	1.36 ns	1.23 ns
16MB	1.68 ns	0.65 ns	8.8 ns	1.22 ns
58MB	2.03 ns	0.70 ns	10.0 ns	1.26〜1.30 ns